

Propensão a depósito a prazo: modelo de ordenação pré-ligação

UCI Bank Marketing · 45.211 contatos · mai/2008 – nov/2010

Elias Queiroga Vieira · 28/09/2026

Código, notebooks e testes: github.com/eliasqueirogavieira/case-kaggle-bank-marketing

Resumo

Pergunta, método e resultado

Tema	Resumo
Pergunta	Ordenar os clientes de uma campanha pela chance de adesão usando só informação disponível antes da ligação; decidir quantos ligar e até quantas tentativas.
Achado de dados	Taxa-base não estacionária (5,1% em 2008 → 51,6% em 2010) confunde perfil e época; duration, campaign, day e month ficam fora do modelo.
Método	LightGBM com offset logit da taxa do mês (init_score): aprende o desvio do cliente em relação ao seu mês. Referências: logística com efeito fixo de mês, regra de negócio, “só o mês”.
Validação	Hold-out 80/20 + CV 5-fold (Optuna, 50 trials) + 2 cortes fora do tempo. Métrica principal: AUC dentro do mês (GAUC).
Resultado	GAUC 0,606 (logística 0,585, regra 0,550); ROC-AUC 0,805, KS 0,49; top 20% por mês capta 29,6% das adesões (regra 27,8%). Fora do tempo: empate com a logística.
Decisão	Ligar se $p \geq C/V$ com p calibrado para a taxa esperada da campanha; limite de 4 tentativas (−21,8% de ligações, −7,4% de adesões).

Dados, alvo e variáveis

Unidade: cliente × campanha; entram só variáveis conhecidas antes da ligação


Item	Valor
Registros	45.211 (sem ID de cliente)
Período	mai/2008–nov/2010 (30 meses)
Alvo	11,7% por cliente · 4,2% por ligação
Baseline de acurácia	88,3% (“nunca adere”)
NaN · duplicatas	0 · 0
“unknown”	job 0,6% · education 4,1% · contact 28,8% · poutcome 81,7%

Grupo	Variáveis	Uso
Perfil	age, job, marital, education, default, balance, housing, loan	modelo
Histórico	pdays, previous, poutcome, contacted_before	modelo
Canal	contact	modelo
Pós-ligação	duration	fora: vazamento
Desfecho	campaign	fora: regra
Calendário	day, month	fora: proxy de época

poutcome = unknown ⇔ pdays = −1 ⇔ previous = 0 (36.954 linhas): recodificado como nonexistent. Demais “unknown” mantidos como categoria (ausência informativa); sem imputação e sem remoção de outliers. Ano reconstruído pela ordem do arquivo (documentação UCI). bank_cleaned.csv descartado (−4.370 linhas, sem contact).

Não estacionariedade: taxa-base de 5,1% a 51,6%

Volume, mix de clientes e política de contato mudam juntos entre 2008 e 2010




- Conversão anual: 5,1% → 17,1% → 51,6%
- Volume mensal: de ~8 mil (mai/08) para ~200–300 contatos (2010)
- Já contatados antes: 3,3% → 65,7%; tentativas médias 3,19 → 1,89
- contact = unknown: 100% de mai–jun/2008 (artefato de registro)

Implicações

- Comparar clientes dentro do mesmo mês
- Validar fora do tempo
- Probabilidade depende da taxa-base da campanha

Confundimento época × perfil

Lift observado na base toda vs. lift ajustado pela taxa do mês de contato




$$\text{lift_aj}(S) = \frac{\sum_{i \in S} y_i}{\sum_{i \in S} r_m(i)}$$

Segmento	Pooled	Mesmo mês
60+ anos	2,87	1,07
Estudante	2,45	1,08
Aposentado	1,95	1,06
Sucesso anterior	5,53	1,61
Fracasso anterior	1,08	0,66
Telefone fixo	1,15	0,79
Com empréstimo	0,57	0,79

r_m também reflete a seleção de clientes do mês: a comparação é conservadora. A logística com efeito fixo de mês confirma as direções.

campaign: viés de sobrevivência e de época

Tratada como regra de contato, não como feature



$$O/E(k) = \frac{\sum 1[\text{campaign}_i = k, y_i = 1]}{\sum_{i: \text{campaign}_i \geq k} r_{\text{call},m(i)}}$$

- $k = 1-4$: O/E 0,97–1,13; $k \geq 5$: 0,62–0,77
- 84% das ligações além da 3ª são de 2008
- Limite de 4: –21,8% ligações, –7,4% adesões; cortadas a 0,62× a média do mês
- Limite de 3 (–29,5%) cortaria ligações ainda a 0,74×

Vazamento: ablação de variáveis (CV 5-fold)

Quanto cada variável excluída infla a métrica

Conjunto de variáveis	ROC-AUC	PR-AUC	GAUC
F0 + offset (modelo final)	0,798	0,451	0,617
F0 sem offset	0,756	0,387	0,607
F1 = F0 + day, month	0,796	0,446	0,632
F2 = F1 + campaign	0,798	0,448	0,634
F3 = F2 + duration	0,937	0,632	0,938

- duration: GAUC 0,634 → 0,938; só existe após a ligação
- day/month: +0,029 de GAUC; data do último contato
- Sem offset, ROC-AUC pooled cai 0,042: parte da AUC pooled é época
- Também evitados: SMOTE antes do split, acurácia como métrica, remoção de outliers por IQR

Modelos e pré-processamento

Pipelines sklearn ajustados apenas no treino de cada fold

	Regra de negócio	Logística (L2)	LightGBM
Entrada	poutcome, housing, loan, balance, contact	F0	F0
Catégoricas	—	one-hot (drop se binária)	one-hot
Numéricas	—	idade em faixas; log-sinal(balance); log1p(pdays+, previous); z-score	brutas
Época	—	efeito fixo de mês	offset: init_score = logit($\tilde{r}_m$)
Hiperparâmetros	pontos fixos (3, 1, 1, 1, 1)	C = 0,1 (grid 0,01–10, CV)	Optuna TPE, 50 trials: 8 folhas, 111 árvores, lr 0,022, min_child 75

$$p_i = \sigma(\text{logit } \tilde{r}_m(i) + f(x_i)) \quad \tilde{r}_m = (\sum_m y + 50 \cdot \bar{y}) / (n_m + 50) \quad \text{score}_i = f(x_i)$$

O score é o desvio do cliente em relação ao seu mês e ordena dentro da campanha. Sem SMOTE nem class_weight: a ordenação não depende de balanceamento e a calibração é preservada.

Desenho de validação e métricas

Seleção no treino, hold-out usado uma vez, robustez fora do tempo

Desenho

- Hold-out estratificado 80/20 (seed 42): 36.168 / 9.043
- StratifiedKFold(5) no treino: modelo, C, Optuna, calibração e ponto de operação (out-of-fold)
- OOT (a): treino $\leq$ abr/09 $\rightarrow$ teste mai/09–nov/10 ($n = 11.034$; 27,4%)
- OOT (b): treino $\leq$ dez/09 $\rightarrow$ teste 2010 ($n = 2.620$; 51,6%)
- IC 95%: bootstrap pareado estratificado por classe (1.000)

Por que GAUC: o baseline “só o mês” atinge ROC-AUC 0,789 sem nenhuma informação do cliente.

Métricas

$$\text{GAUC} = \sum_m U_m / \sum_m n^+_m \cdot n^-_m$$

- GAUC (principal): AUC entre pares do mesmo mês
- Captura e lift@20% dentro do mês
- ROC-AUC, Gini, KS, PR-AUC (pooled; PR-AUC aleatório = 0,117)
- Brier e curva de calibração

Resultados no hold-out (n = 9.043)

LightGBM supera logística e regra em GAUC; no top 20% a diferença é pequena



Modelo	GAUC	Captura@20%	ROC-AUC	KS	PR-AUC	Brier
Dummy (taxa média)	0,500	20,0%	0,500	0,00	0,117	0,103
Só o mês	0,500	20,0%	0,789	0,47	0,378	0,084
Regra de negócio	0,550	27,8%	0,714	0,33	0,285	—
Logística + efeito do mês	0,585	30,2%	0,802	0,49	0,470	0,079
LightGBM padrão	0,611	28,5%	0,802	0,49	0,462	0,081
LightGBM ajustado + offset	0,606	29,6%	0,805	0,49	0,465	0,080

Δ GAUC (IC 95%, bootstrap pareado)	Valor
LightGBM – logística	+0,021 [0,006; 0,036]
LightGBM – regra	+0,056 [0,030; 0,083]
LightGBM ajustado – padrão	−0,005 [−0,022; 0,012]

CV no treino: 0,617 ± 0,006 (LightGBM) vs 0,603 ± 0,015 (logística). Captura@20%: fração das adesões no top 20% do score de cada mês. Métricas pooled usam a taxa do mês.

Ordenação e calibração

Ganho dentro do mês no hold-out e calibração out-of-fold



- 1º decil: 19,3% de adesão (1,65×); 10º: 6,4%
- Top 20% por mês: 29,6% das adesões
- Calibração OOF: desvio máximo 2,1 p.p.; Brier 0,081 vs 0,103 do baseline
- Sem Platt nem isotônica

Validação fora do tempo

O ranking se mantém; o LightGBM não supera a logística fora do tempo

GAUC	(a)	(b)
LightGBM + offset	0,625	0,698
LightGBM sem offset	0,635	0,687
Logística + efeito do mês	0,628	0,709
Regra de negócio	0,598	0,699


Δ GAUC (IC 95%)	(a)	(b)
LightGBM – logística	-0,003 [-0,013; 0,007]	-0,010 [-0,020; 0,000]
LightGBM – regra	+0,028 [0,006; 0,050]	-0,000 [-0,014; 0,014]



(a) treino $\leq$ abr/09 (6,6%) $\rightarrow$ teste mai/09–nov/10 (27,4%). (b) treino $\leq$ dez/09 $\rightarrow$ 2010 (51,6%). LightGBM mantido pelo critério pré-definido (CV); logística como challenger.

Interpretação: efeitos dentro do mês

SHAP exato (TreeSHAP) e odds ratios da logística com efeito fixo de mês



Contraste (mesmo mês)	OR
Sucesso anterior vs. nunca contatado	3,30
18–25 vs. 36–45 anos	1,39
Solteiro vs. casado	1,28
Com crédito imobiliário	0,72
Com empréstimo pessoal	0,82
Telefone fixo vs. celular	0,67
Fracasso anterior vs. nunca	0,56

Sem offset, o modelo usa proxies de época: 6,2× o peso no canal, 3,8× na idade, 2,8× no crédito imobiliário.

Decisão: quantos ligar

Valor esperado com probabilidade calibrada para a taxa esperada da campanha

ligar se $p_i \geq C/V$

$p_i = \sigma(s_i + c^*)$, $c^*: (1/n) \cdot \sum_i \sigma(s_i + c^*) = \hat{r}$

- Um único deslocamento por lote: a ordem não muda
- $\hat{r}$: taxa esperada da campanha (ex.: mês anterior)
- $C = €10$, $V = €100$ (ilustrativos) $\Rightarrow p^* = 10\%$
- OOF por ano: em 2008 ligar para todos dá $-€4.892/1.000$ e a regra liga para 0,7%; em 2009 rende +22%; em 2010 = ligar para todos

OOT (a), taxa real 27,4%

Estratégia	Ligados	Brier	€ / 1.000
$p \geq C/V$, $\hat{r}$ = taxa do treino	14,6%	0,238	5.400
$p \geq C/V$, $\hat{r}$ = mês anterior	84,9%	0,167	16.880
$p \geq C/V$, $\hat{r}$ = taxa real	70,8%	0,159	18.434
Ligar para todos	100,0%	—	17.361
Top 20% de cada mês	20,0%	—	5.765

Produção, monitoramento e limitações

Pontuação em lote antes de cada campanha

Produção



- predict em lote: score, decil, prioridade, p (dado $\hat{r}$) e 3 motivos (TreeSHAP; idade nunca exibida)
- Mesmo código de features no treino e na pontuação; artefato joblib + metadata (hash dos dados, versões, métricas)
- Monitoramento: PSI de features e do score (2008 $\rightarrow$ 2010: 0,63); GAUC em janela de 3 meses; calibração por campanha
- Retreino trimestral ou por gatilho (PSI > 0,25; GAUC < 0,58 na janela; calibração ± 5 p.p.)
- A/B com 10% aleatório: ganho incremental e dados sem viés de seleção; champion/challenger LightGBM $\times$ logística

Limitações e próximos passos

- Sem ID de cliente: o mesmo cliente pode estar no treino e no teste do split aleatório (OOT mitiga)
- Só clientes contatados (viés de seleção); C e V ilustrativos
- 2,5 anos com drift forte: sazonalidade não identificável
- Próximos: variáveis macro (bank-additional), uplift modeling, custos reais, piloto A/B

Apêndice · Otimização (CV e Optuna)



GAUC por modelo em CV 5-fold e histórico da busca TPE



Melhores hiperparâmetros: learning_rate 0,022 · n_estimators 111 · num_leaves 8 · min_child_samples 75 · subsample 0,80 · colsample_bytree 0,64 · reg_lambda 5,59. 37 de 50 trials a $\leq 0,003$ do melhor; Optuna e comparação compartilham os folds (viés desprezível).


Apêndice · Curvas ROC e precisão × recall

Hold-out, métricas pooled



Apêndice · Ponto de operação top 20% por mês



Matriz de confusão no hold-out



Métrica	Valor
Precisão	17,3%
Recall	29,3%
F1	0,217
Acurácia	75,3%
Baseline “nunca adere”	88,3%

Apêndice · SHAP: beeswarm e dependência

Modelo final, hold-out



Apêndice · Regra de custo: por ano e sensibilidade

Predições out-of-fold do treino, C = €10

Ano (OOF)	Ligados pela regra	Regra € / 1.000	Todos € / 1.000
2008	0,7%	155	-4.892
2009	56,6%	8.630	7.054
2010	100,0%	41.357	41.357

V/C	p*	Ligados	Regra € / 1.000	Todos € / 1.000
10	10%	24,9%	5.309	1.698
20	5%	64,1%	14.355	13.396
5	20%	14,2%	1.776	-4.151

Apêndice · Reprodutibilidade

Repositório, ambiente e testes

```
uv sync
uv run pytest # 74 testes
uv run jupyter nbconvert --execute notebooks/*.ipynb
uv run python -m bank_marketing.train
uv run python -m bank_marketing.predict --input clientes.csv \
--output lista.csv --top 0.2 --base-rate 0.12
```

- uv.lock + requirements.txt; seed 42; LightGBM determinístico
- Testes: reconstrução do período, guarda anti-vazamento, métricas contra casos calculados à mão, CLIs
- Números dos slides: reports/metrics.json